


Synthèse de vidéos de personnes parlant à partir d'un fichier audio et d'une image du visage



Présentée par : **Sara Taibi**

Encadré par: **El Karfi Ikram**

Le Plan



01

Introduction

02

Technologies
Utilisées

03

Dataset et
Prétraitement des
Données

04

Modèles utilisés

05

Comparaison avec
d'autres Modèles

06

Réalisation et
Conclusion



01

Introduction

Problématique et Solution



INTRODUCTION

La synthèse labiale est une technique permettant de générer une vidéo d'un visage parlant à partir d'un **fichier audio** et d'une **image statique du visage** .

Grâce aux avancées du **deep learning**, notamment avec les modèles comme **Wav2Lip**, il est aujourd'hui possible de produire des vidéos réalistes et parfaitement synchronisées.

Problématique

Comment générer une vidéo réaliste d'un visage parlant, à partir d'un simple audio et d'une image ou bien vidéo, tout en assurant une synchronisation naturelle et fidèle ?



Manque de généralisation sur différents visages, langues ou accents.



Mauvaise synchronisation entre l'audio et le mouvement des lèvres.



Présence d'artéfacts visuels qui nuisent à la qualité de la vidéo.



02

Technologies utilisées

Les outils utilisés pour le development

colab



gradio





03

Dataset et prétraitement des données

Comprehension de dataset et prétraitement

Compréhension des données

Le nombre de dossiers : 3 783

▼ mvlrs_v1

▼ main

- ▶ 5535415699068794046
- ▶ 5535423430009926848
- ▶ 5535496873950688380
- ▶ 5535864093654496929
- ▶ 5536038039829982468
- ▶ 5536266102593401990
- ▶ 5536745420943636139
- ▶ 5536760882825901738
- ▶ 5536876846942893978
- ▶ 5536915501648559593
- ▶ 5536968329746298779
- ▶ 5537143564411975377

5535415699068794046

- 00001.mp4
- 00001.txt
- 00002.mp4
- 00002.txt
- 00003.mp4
- 00003.txt
- 00004.mp4
- 00004.txt
- 00006.mp4
- 00006.txt
- 00007.mp4
- 00007.txt

Le dossier 5535415699068794046

Nombre de vidéos : 11

Nombre de fichiers texte : 11

Contenu de 00014.txt:

Text: THE INSIDE SHOULD BE NICE AND SOFT AND REALLY OOZE OUT
Conf: 4

Contenu de 00006.txt:

Text: APART FROM THE GOLDEN COLOUR AND THE DELICIOUS FLAVOUR
Conf: 2

Contenu de 00013.txt:

Text: I COULD LABEL THIS ON THE INGREDIENTS AS MEAT
Conf: 2

Prétraitement des données (Objectif)



Détection du visage image par image (frame) dans chaque vidéo.



Extraction de l'audio en .wav en mono et à 16 kHz, pour qu'il soit compatible avec le modèle




Organisation dans une structure de dossiers claire.

Prétraitement – Exécution

```
!python preprocess.py --data_root mvlrs_v1/main  
|--preprocessed_root lrs2_preprocessed/
```

- ▼ lrs2_preprocessed
 - ▼ 5535415699068794046
 - ▶ 00001
 - ▶ 00002
 - ▶ 00003
 - ▶ 00004
 - ▶ 00006
 - ▶ 00007
 - ▶ 00008
 - ▶ 00009
 - ▶ 00011
 - ▶ 00013
 - ▶ 00014





04

Modèles utilisées

Wav2Lip et Wav2Lip+GAN

Wav2Lip

Wav2Lip est un modèle de deep learning conçu pour la **synchronisation audio-labiale**, c'est-à-dire faire en sorte que les mouvements des lèvres d'un visage dans une vidéo correspondent parfaitement à une piste audio. Ce modèle est particulièrement utile dans des contextes comme le doublage vidéo, la génération de contenu, ou l'amélioration de la parole dans des vidéos muettes ou altérées.

Téléchargement du modèle Wav2Lip

❖ Cloner le dépôt GitHub


```
[ ] !git clone https://github.com/Rudrabha/Wav2Lip.git
```

❖ Installer les dépendances nécessaires :

```
▶ corrected_requirements = """  
librosa==0.8.1  
numpy==1.23.5  
opencv-contrib-python>=4.5.5.64  
tqdm==4.66.1  
numba==0.57.1  
"""  
  
with open("/content/drive/MyDrive/Wav2Lip/requirements.txt", "w") as f:  
    f.write(corrected_requirements)
```


```
[ ] !cd /content/drive/MyDrive/Wav2Lip && pip install -r requirements.txt
```

Architecture du modèle :




Entrées et traitement initial

- ① Input Audio : Audio d'entrée capturé.
- ② Mel-spectrogram : Conversion spectrographique.
- ③ Audio Encoder : Extraction des caractéristiques audio.
- ④ Random Segment : Segment de visage masqué.
- ⑤ Face Encoder : Encodage des caractéristiques visuelles.
- ⑥ Cross Attention : Fusion audio-visuelle.




Génération et finalisation



- 6 Cross Attention : Fusion audio-visuelle (rappel).
- 7 Face Decoder : Génération du segment de visage.
- 8 Face Restoration : Amélioration de la qualité visuelle.
- 9 Generated Face Segment : Résultat final synchronisé.
- 10 Losses : Sync Loss (synchronisation) et L1 Loss (précision).

Wav2Lip+GAN



Wav2Lip+GAN

Entraînement du modèle

Entraînement de SyncNet

total trainable params 16435072

0it [00:00, ?it/s] Saved checkpoint: /kaggle/working/checkpoints_syncnet/checkpoint_step000000001.pth

Loss: 0.6880419211906369: : 717it [11:17, 1.06it/s]

Loss: 0.603616510059378: : 717it [11:17, 1.06it/s]

Loss: 0.5060096909727179: : 717it [11:13, 1.06it/s]

Loss: 0.4422053153960442: : 717it [11:15, 1.06it/s]

Loss: 0.39747925719955474: : 717it [11:12, 1.07it/s]

Loss: 0.3682805599652574: : 717it [11:10, 1.07it/s]

Loss: 0.3383135293276573: : 717it [11:18, 1.06it/s]

Loss: 0.3168488015190827: : 717it [11:16, 1.06it/s]

Loss: 0.29718849987747614: : 717it [11:06, 1.07it/s]

Loss: 0.2836145437121225: : 717it [11:11, 1.07it/s]

Loss: 0.27174413102358125: : 717it [11:23, 1.05it/s]

Loss: 0.2568420141395: : 717it [11:13, 1.06it/s]

Loss: 0.2494134614283071: : 717it [11:12, 1.07it/s]

Loss: 0.24242594388689967: : 678it [10:46, 1.36it/s] Saved checkpoint: /kaggle/working/checkpoints_syncnet/checkpoint_step000010000.pth

Evaluating for 1400 steps

Sauvgardage des checkpoints

checkpoint_step000000001.pth

checkpoint_step000010000.pth

checkpoint_step000020000.pth

checkpoint_step000030000.pth

checkpoint_step000040000.pth

checkpoint_step000050000.pth

checkpoint_step000060000.pth

Entraînement de Wav2Lip

```
use_cuda: True
/usr/local/lib/python3.11/dist-packages/torch/utils/data/dataloader.py:560: UserWarnin
g: This DataLoader will create 16 worker processes in total. Our suggested max number
of worker in current system is 4, which is smaller than what this DataLoader is going
to create. Please be aware that excessive worker creation might get DataLoader running
slow or even freeze, lower the worker number to avoid potential slowness/freeze if nec
essary.
  warnings.warn( create warning msg(
total trainable params 36298035
Load checkpoint from: /kaggle/working/checkpoints_syncnet/checkpoint_step000010000.pth
Starting Epoch: 0
0it [00:00, ?it/s]Saved checkpoint: /kaggle/working/checkpoints_wav2lip/checkpoint_ste
p000000001.pth
Evaluating for 700 steps
```



05

Comparaison avec d'autres modèles

Comparison des modèles

Performance de Synchronisation

Method	Video Type	LSE-D ↓	LSE-C ↑	FID ↓	Sync Acc.	Visual Qual.	Overall Experience	Preference
Unsynced Orig. Videos	Dubbed	12.63	0.896	—	0.21	4.81	3.07	3.15%
Speech2Vid [17]		14.76	1.121	19.31	1.14	0.93	0.84	0.00%
LipGAN [18]		10.61	2.857	12.87	2.98	3.91	3.45	2.35%
Wav2Lip (ours)		6.843	7.265	15.65	4.13	3.87	4.04	34.3%
Wav2Lip + GAN (ours)		7.318	6.851	11.84	4.08	4.12	4.13	60.2%
Without Lip-syncing	Random	17.12	2.014	—	0.15	4.56	2.98	3.24%
Speech2Vid [17]		15.22	1.086	19.98	0.87	0.79	0.73	0.00%
LipGAN [18]		11.01	3.341	14.60	3.42	3.77	3.57	3.16%
Wav2Lip (ours)		6.691	8.220	14.47	4.24	3.68	4.01	29.1%
Wav2Lip + GAN (ours)		7.066	8.011	13.12	4.18	4.05	4.15	64.5%
Without Lip-syncing	TTS	16.89	2.557	—	0.11	4.67	3.32	8.32%
Speech2Vid [17]		14.39	1.471	17.96	0.76	0.71	0.69	0.00%
LipGAN [18]		10.90	3.279	11.91	2.87	3.69	3.14	1.64%
Wav2Lip (ours)		6.659	8.126	12.77	3.98	3.87	3.92	41.2%
Wav2Lip + GAN (ours)		7.225	7.651	11.15	3.85	4.13	4.05	51.2%
Untranslated Videos		7.767	7.047	—	4.83	4.91	—	—

Table 2: Real world evaluation using our newly collected ReSyncED benchmark. We evaluate using both quantitative metrics and human evaluation scores across three classes of real videos. We can see that in all cases, the Wav2Lip model produces high-quality, accurate lip-syncing videos. Specifically, the metrics indicate that our lip-synced videos are as good as the real synced videos. We also note that human evaluations indicate that there is a scope for improvement when trying to lip-sync TTS generated speech. Finally, it is worth noting that our lip-synced videos are preferred over existing methods or the actual

06

Réalisation et conclusion



Réalisation de l'application

Conclusion

- Ce projet montre qu'il est possible de générer des vidéos réalistes d'un visage parlant à partir d'une simple image et d'un fichier audio. Le modèle **Wav2Lip**, surtout avec l'ajout du **GAN**, offre une excellente synchronisation labiale et une grande qualité visuelle. Des améliorations futures peuvent porter sur la diversité des voix, des visages et des langues pour renforcer la généralisation du modèle.



**Merci pour votre
attention**